



QUARTER-CAR

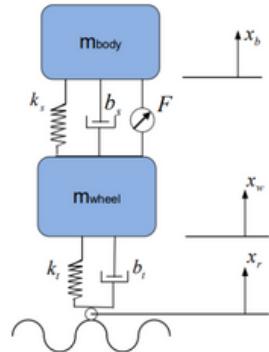
REFERENCIAS

- P. SENTHIL KUMAR, K. SIVAKUMAR, R. KANAGARAJAN, AND S. KUBERAN, "ADAPTIVE NEURO FUZZY INFERENCE SYSTEM CONTROL OF ACTIVE SUSPENSION SYSTEM WITH ACTUATOR DYNAMICS," JOURNAL OF VIBROENGINEERING, VOL. 20, NO. 1, PP. 541-549, FEB. 2018, DOI: 10.2159/JVE.2017.18379.
- T. ABUT AND E. SALKIM, "CONTROL OF QUARTER-CAR ACTIVE SUSPENSION SYSTEM BASED ON OPTIMIZED FUZZY LINEAR QUADRATIC REGULATOR CONTROL METHOD," APPLIED SCIENCES, 2023.
- DE LA PENA, T., ANGEL, I., IRIGOYEN, ELOY, LARREA, MIKEL. 2025. ENSEMBLE MODELS WITH NEURAL NETWORKS FOR SYSTEM IDENTIFICATION., JORNADAS DE AUTOMÁTICA, 46. HTTPS://DOI.ORG/10.17979/JA-CEA.2025.46.12205

JUAN SOTEO R., JULIÁN PÉREZ C., ANDRÉS SALAZAR M.

PLANTAMIENTO DEL PROBLEMA

1. MODELO



2. ECUACIONES

$$\begin{aligned} m_b \ddot{x}_b + b_s (\dot{x}_b - \dot{x}_w) + k_s (x_b - x_w) - F_s &= 0 \quad (1) \\ m_w \ddot{x}_w + b_t (\dot{x}_w - \dot{x}_r) + k_t (x_w - x_r) - k_s (x_b - x_w) - F_s &= 0 \quad (2) \\ \ddot{x}_b = -\frac{1}{m_b} [b_s (\dot{x}_b - \dot{x}_w) + k_s (x_b - x_w) - F_s] &\quad (3) \\ \ddot{x}_w = -\frac{1}{m_w} [b_t (\dot{x}_w - \dot{x}_r) + k_t (x_w - x_r) - b_s (\dot{x}_b - \dot{x}_w) - k_s (x_b - x_w) - F_s] &\quad (4) \end{aligned}$$

3. REPRESENTACIÓN EN ESPACIO DE ESTADOS

Las matrices A y B se obtienen del modelo dinámico como:

$$\dot{x} = \begin{bmatrix} 0 & 1 & 0 & 0 \\ -k_s & -b_s & k_s & b_s \\ m_b & m_b & m_b & m_b \\ 0 & 0 & 0 & 1 \end{bmatrix} * \begin{bmatrix} x_b \\ \dot{x}_b \\ x_w \\ \dot{x}_w \end{bmatrix} + \begin{bmatrix} 0 & 0 \\ 0 & 1 \\ 0 & m_b \\ 0 & 0 \end{bmatrix} * \begin{bmatrix} F_s \\ x_r \end{bmatrix}$$

Las salidas de interés son:

$$\begin{aligned} y_1 &= x_b, && \text{(Desplazamiento de la carrocería)} \\ y_2 &= \dot{x}_b, && \text{(Aceleración de la carrocería)} \\ y_3 &= x_b - x_w, && \text{(Deflexión de la suspensión)} \end{aligned}$$

Por lo tanto, las matrices C y D se definen como:

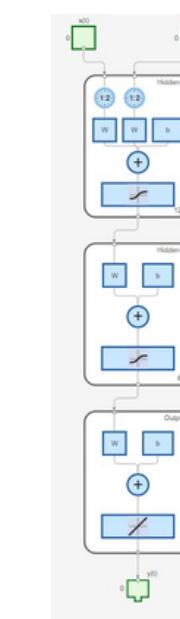
$$y = \begin{bmatrix} 1 & 0 & 0 & 0 \\ -\frac{k_s}{m_b} & -\frac{b_s}{m_b} & \frac{k_s}{m_b} & \frac{b_s}{m_b} \\ 1 & 0 & -1 & 0 \end{bmatrix} * \begin{bmatrix} x_b \\ \dot{x}_b \\ x_w \\ \dot{x}_w \end{bmatrix} + \begin{bmatrix} 0 & 0 \\ 0 & \frac{1}{m_b} \\ 0 & 0 \end{bmatrix} * \begin{bmatrix} F_s \\ x_r \end{bmatrix}$$

OBJECTIVO

Se busca un control que reduce la aceleración vertical de la carrocería, contiene las deflexiones y mantiene el contacto rueda-carretera.

METODO DE IDENTIFICACIÓN CON REDES NEURONALES (NN)

1. MODELO



2. MÉTRICAS DE RENDIMIENTO

Salida 1 (y_1 (Posición, m)):

MAE: 1.6694e-04
MSE: 8.6650e-08
RMSE: 2.9436e-04
Error Máximo: 5.4744e-03

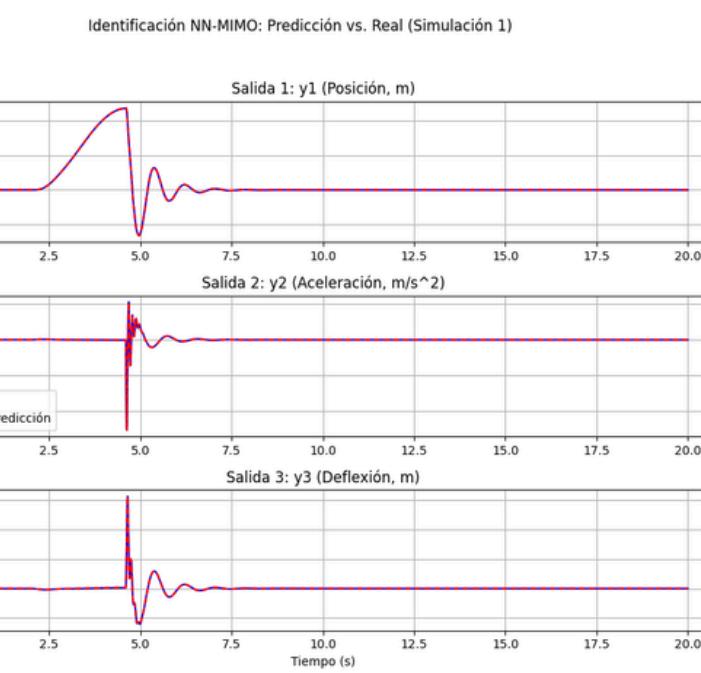
Salida 2 (y_2 (Aceleración, m/s^2)):

MAE: 9.4037e-03
MSE: 7.0106e-04
RMSE: 2.6477e-02
Error Máximo: 7.0284e-01

Salida 3 (y_3 (Deflexión, m)):

MAE: 5.9341e-05
MSE: 1.2808e-08
RMSE: 1.1317e-04
Error Máximo: 3.3269e-03

3. RESULTADOS



4. ANALÍSIS

El modelo NN propuesto logró una identificación precisa de la dinámica del sistema de suspensión en los tres estados evaluados, como se ve en los resultados las curvas simuladas se superponen casi por completo con las señales reales.

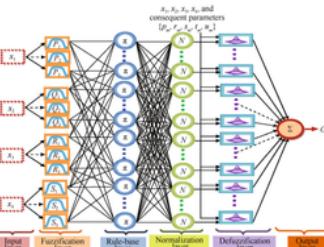
Las métricas de error MAE, MSE, RMSE y Error Máximo muestran valores muy bajos en todas las salidas, en especial en la posición (y_1) y deflexión (y_3) los cuales presentan errores del orden de 10^{-4} , por otro lado la aceleración (y_2) muestra el mayor error relativo, resultado que es esperable debido a que esta variable depende de derivadas segundas del desplazamiento, además de que tiene un rango de valores mucho más amplio.

METODO DE IDENTIFICACIÓN CON SISTEMA ADAPTATIVO DE INFERNERIA NEURO-DIFUSA (ANFIS)

1. MODELO

El modelo ANFIS fue entrenado con una arquitectura que incluye:

- 4 entradas,
- 3 funciones de membresía gausianas (gaussmf) por entrada,
- 81 reglas difusas,
- 100 épocas de entrenamiento.



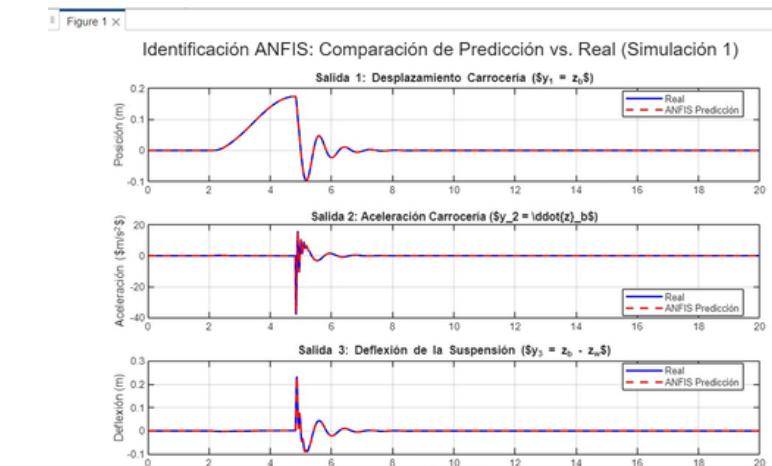
2. MÉTRICAS DE RENDIMIENTO

=====
== Rendimiento de Identificación ANFIS para las TRES Salidas ==
=====

Arquitectura: 3 MFs (Gaussmf), 81 Reglas, 100 Épocas

| Salida | MAE | MSE | RMSE | ErrorMax |
|--------|------------|------------|------------|-----------|
| {'y1'} | 7.5755e-06 | 2.9981e-09 | 5.4755e-05 | 0.0016634 |
| {'y2'} | 0.032256 | 0.21053 | 0.45884 | 26.442 |
| {'y3'} | 9.7702e-05 | 7.2708e-07 | 0.00085269 | 0.032836 |

3. RESULTADOS



4. ANALÍSIS

El modelo ANFIS mostró un alto desempeño en la identificación del sistema del quarter-car. La salida 1 correspondiente al desplazamiento de la carrocería presenta un error prácticamente nulo por lo que la dinámica de este primer estado fue identificado de forma precisa y estable.

La salida 2 correspondiente a la aceleración de la carrocería es la variable con mayor error, aunque la tendencia general se conserva existen discrepancias en los picos de la aceleración.

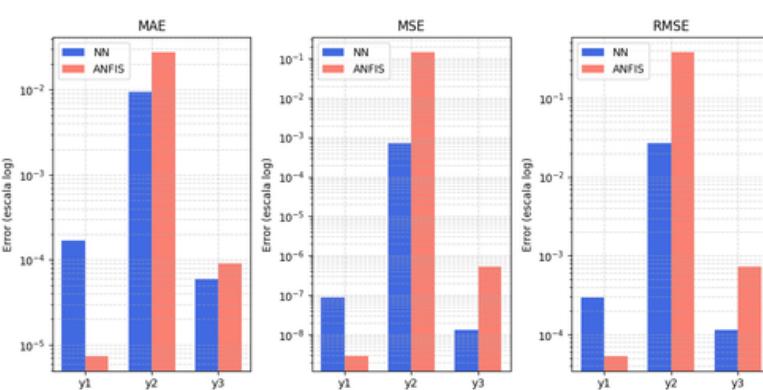
La salida 3, Deflexión de la suspensión también reproduce una respuesta fiel a la dinámica del sistema, con algunas pequeñas desviaciones durante el impacto.

COMPARACIÓN

Al comparar el desempeño entre los modelos NN y ANFIS implementados para reconocer el sistema dinámico, se observa que ambos logran una identificación precisa del sistema, reproduciendo de manera fiel la dinámica de los 3 estados.

El modelo NN presentó un buen ajuste global, con errores mínimos en la posición y deflexión, aunque mayor desviación en la aceleración. Por su parte, el modelo ANFIS alcanzó errores aun menores en el desplazamiento demostrando una mejor capacidad de aproximación, pero también mostró un incremento de error en la aceleración por la complejidad no lineal de la señal.

Comparación de métricas de error entre NN y ANFIS



CONCLUSIÓN

En la identificación del sistema dinámico correspondiente al modelo de un quarter-car mediante redes neuronales y ANFIS, demostró que ambas técnicas son efectivas para modelar dinámicas con una buena precisión.

Los resultados obtenidos evidencian que el modelo NN logra una buena capacidad de generalización y estabilidad, mientras que ANFIS ofreció una mayor exactitud en las regiones de entrenamiento gracias a su estructura basada en reglas difusas.

Se concluye que la integración de métodos de aprendizaje automático en la identificación de sistemas permite capturar comportamientos complejos con bajo error y una alta fidelidad, siendo estos métodos una alternativa sólida frente a modelos tradicionales.