

Taller 2



Integrantes:

Juan Pablo Sotelo Rativa – 20211020113

Andrés Felipe Salazar Malagón - 20202020043

Julián David Pérez Chaparro - 20192020017

Docente:

Duvan Andres Tellez Castro

Universidad Distrital Francisco José de Caldas

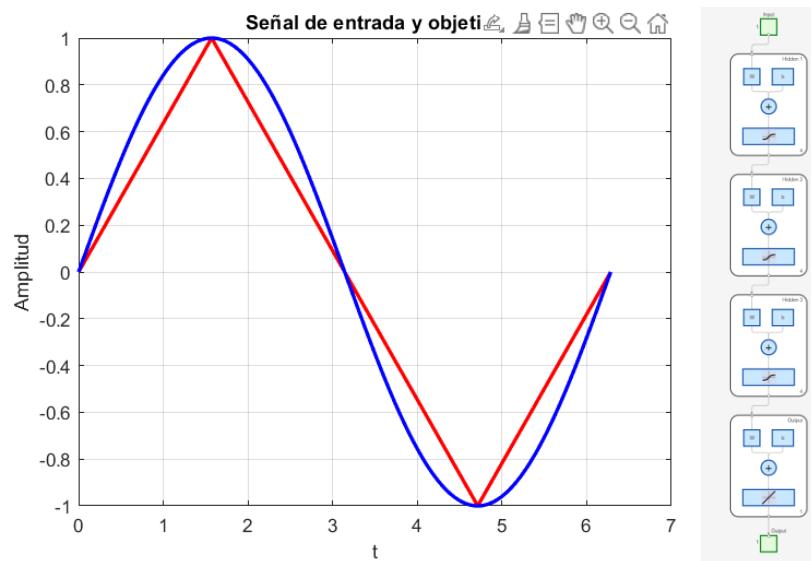
Facultad de Ingeniería

Cibernética III

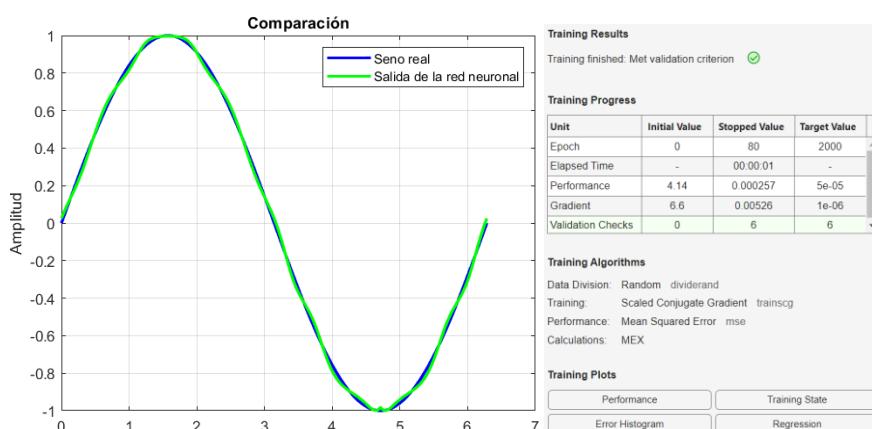
2025

Punto 2:

Se diseñó una red neuronal feedforward para convertir una señal triangular ($x(t)$) en una señal senoidal ($y(t)$), de acuerdo con la Figura 1 del enunciado. Se utilizó una arquitectura 3 capas ocultas con 4 neuronas por capa [4 4 4], cumpliendo la restricción “capas ocultas: 3–4; neuronas por capa: 3–4”. El entrenamiento se realizó con Scaled Conjugate Gradient (trainscg), 2000 épocas y meta de desempeño. Se mantuvieron las activaciones por defecto de MATLAB tansig en capas ocultas y lineal en la salida.



Resultados obtenidos: La red logra aproximar la salida senoidal con alta fidelidad. Se midió el desempeño sobre la señal normalizada respecto a su valor máximo, obteniéndose: error máximo = 0.032762 (3.2763 %, menor al 5 % exigido), error cuadrático medio=0.0002 (menor al 2 % solicitado) y error relativo promedio 3.2763 %. La respuesta sigue la forma de onda seno sin distorsiones relevantes; las pequeñas discrepancias se concentran alrededor de crestas y valles, coherentes con la complejidad local de la transformación y la capacidad del modelo 4–4–4. La configuración cumple plenamente los requerimientos del punto: límites de error máximo y MSE por debajo de lo exigido y arquitectura dentro de los rangos permitidos.



Punto 3:

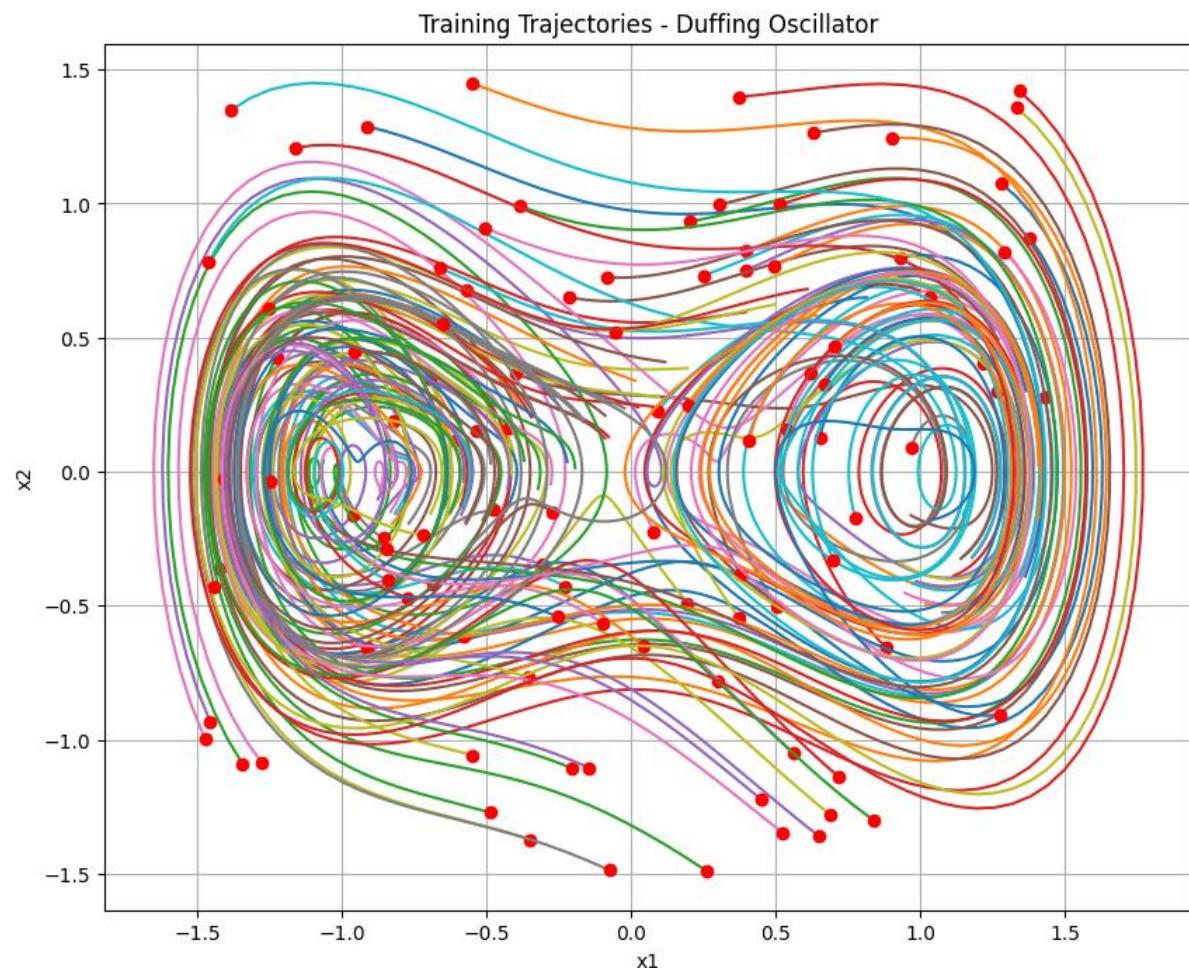
Se seleccionó el oscilador de Duffing como sistema caótico bidimensional. Su origen se remonta a inicios del siglo XX, cuando Georg Duffing modeló osciladores mecánicos con rigidez no lineal para describir resortes “endurecientes/ablandantes”. El modelo clásico incorpora amortiguamiento y excitación periódica, y añade un término cúbico x_1^3 que rompe la linealidad. Décadas después, con el auge de la dinámica no lineal, se mostró que este sistema exhibe histeresis, bifurcaciones y regímenes caóticos aún bajo excitaciones periódicas simples; físicamente aparece en vigas flexibles, circuitos RLC no lineales y sistemas vibro-mecánicos con potencial de doble pozo, lo que explica los retratos de fase tipo “mariposa” observados.

Generación de datos:

Se integró el sistema durante $T=8$ s con paso $t=0.05$ usando el campo vectorial:

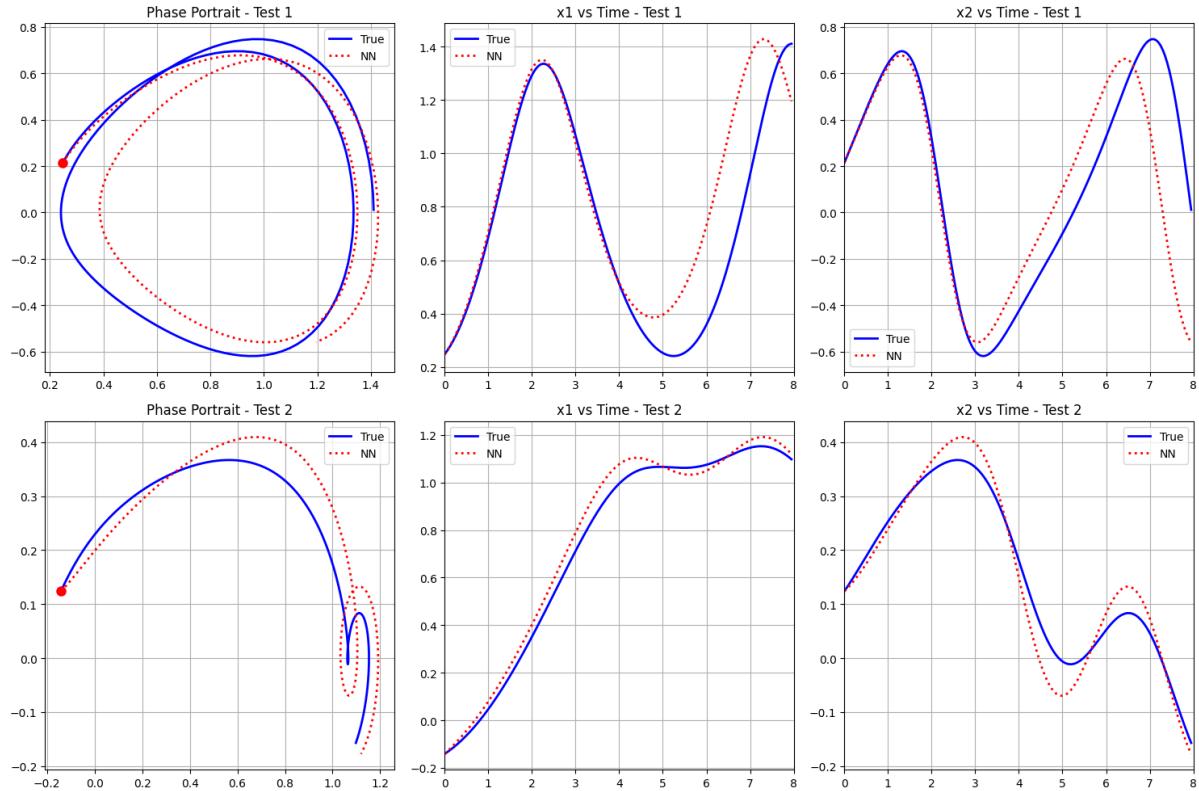
$$\dot{x}_1 = x_2, \dot{x}_2 = x_1 - x_1^3 - ax_2 + b \cos(\omega t)$$

con parámetros $a=0.35$, $b=0.3$, $\omega=1$. Se muestrearon múltiples condiciones iniciales para cubrir ambas “cubetas” del potencial y obtener trayectorias variadas del atractor.



Red neuronal:

Para predecir la evolución de los **estados** (x_1, x_2) a partir de (x_1, x_2, t) se entrenó una MLP ligera (entrada 3 → ocultas 5–5 con Tanh → salida 2 lineal). Se utilizó Adam (lr = 1e-3) y MSE como función de pérdida, durante 1000 épocas. Esta implementación en PyTorch permitió entrenamientos mini-batch más eficientes que en MATLAB para este conjunto de trayectorias.



Resultados obtenidos:

- MSE (porcentaje): 0.2836 % cumple el requisito MSE < 2 %.
- MAE (porcentaje): 4.0621 %.
- En las figuras de validación, la red reproduce adecuadamente la geometría del retrato de fase y las series temporales; los mayores desajustes aparecen cerca de cambios de curvatura y picos de la respuesta, propios de la dinámica no lineal forzada.

El atractor de Duffing es una elección pertinente por su riqueza caótica y su presencia en sistemas físicos reales. La arquitectura (3→5→5→2, Tanh) entrenada con Adam reproduce con fidelidad las trayectorias, cumpliendo el umbral de MSE < 2 % durante ventanas de al menos 2 s y mostrando un MAE < 5 %.

Punto 4

El experimento consistió en entrenar un sistema ANFIS (Adaptive Neuro-Fuzzy Inference System) para que aprendiera la relación entre una señal triangular (entrada) y una señal senoidal (salida deseada).

El proceso se realizó en MATLAB, utilizando el modelo de simulación , con el objetivo de

analizar la influencia del tipo y número de funciones de membresía (MF) en la precisión del modelo.

Se emplearon dos tipos de funciones de membresía: triangular (trimf) y gaussiana (gaussmf), con configuraciones de 5 y 7 MF respectivamente.

El sistema difuso inicial se generó con genfis1, basado en un modelo Takagi-Sugeno con salida lineal.

Posteriormente, se entrenó mediante el comando anfis([entrada salida], fis_inicial, 25) durante 25 épocas, ajustando los parámetros de las reglas y las funciones de membresía para minimizar el error cuadrático medio (ECM).

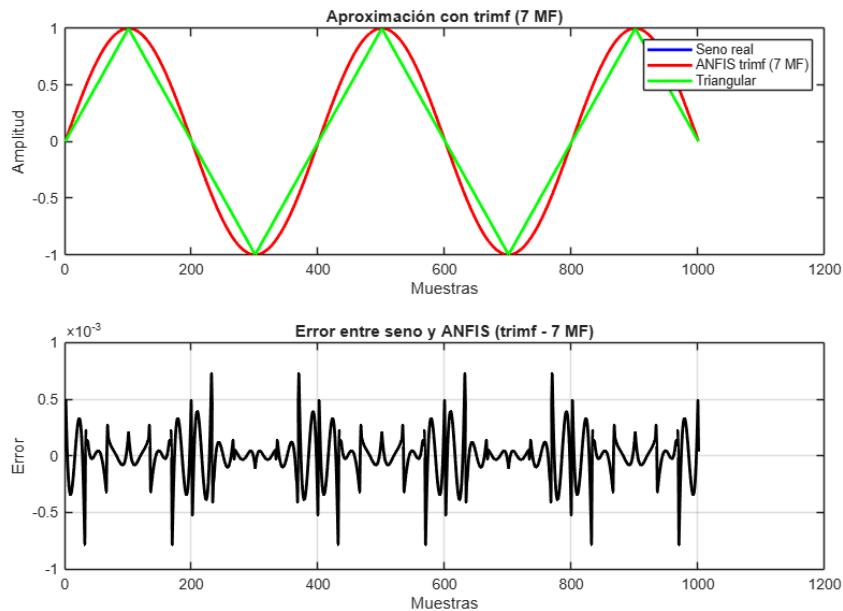
Una vez entrenado, el sistema se evaluó con evalfis, obteniendo la salida aproximada del ANFIS.

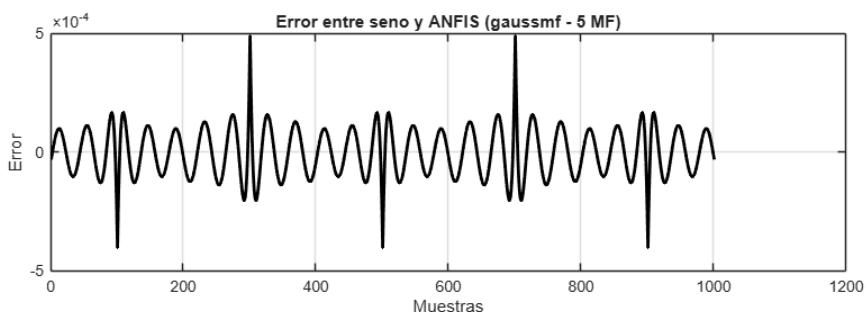
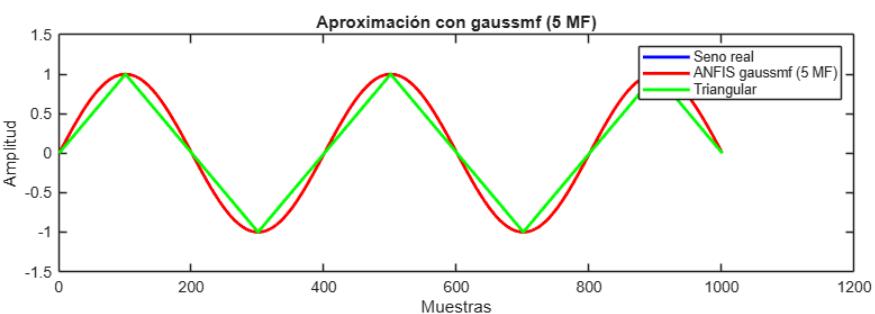
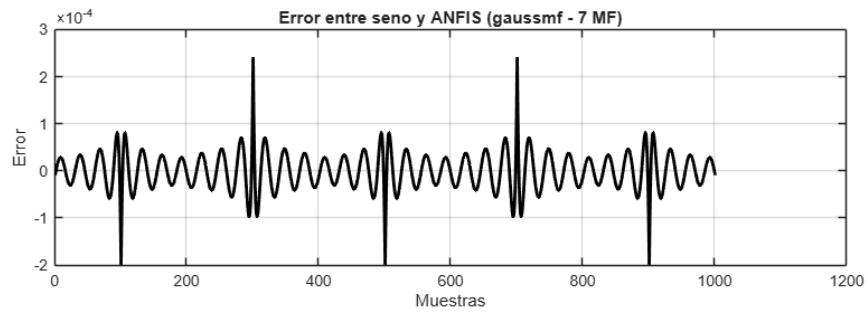
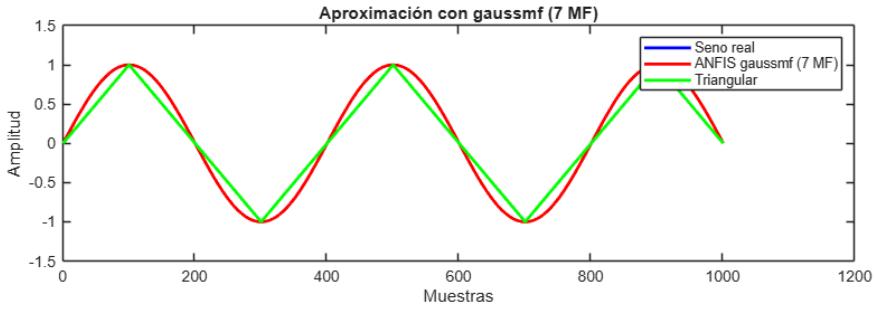
Finalmente, se calcularon los indicadores de desempeño:

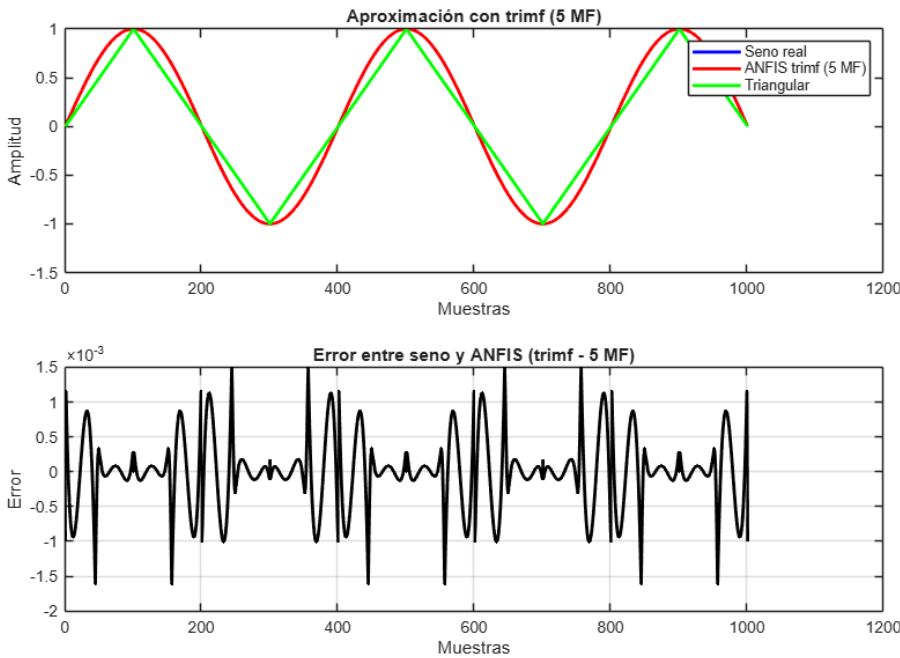
ECM (Error Cuadrático Medio): mide la precisión global del modelo.

Error Máximo (%): cuantifica la desviación máxima respecto a la señal real.

Los resultados se compararon para determinar cuál configuración ofrecía mejor desempeño en la aproximación del seno.







Análisis de resultados

En las simulaciones se probaron cuatro configuraciones del sistema ANFIS, variando el tipo de función de membresía (MF) y el número de funciones.

Los resultados obtenidos fueron los siguientes:

Tipo de MF	Nº MF	ECM	Error Máx (%)
gaussmf	5	1.05×10^{-8}	0.0489
gaussmf	7	1.57×10^{-9}	0.0239
trimf	5	2.59×10^{-7}	0.1609
trimf	7	3.51×10^{-8}	0.0783

Se observa que el tipo de función gaussmf ofrece un rendimiento superior en comparación con la trimf, tanto en el error cuadrático medio (ECM) como en el error máximo.

Esto se debe a que las funciones gaussianas tienen una transición más suave y permiten una mejor interpolación entre reglas difusas, logrando una mayor capacidad de ajuste a la señal senoidal.

Además, el aumento de 5 a 7 funciones de membresía mejora el desempeño en ambos casos, ya que incrementa la resolución del espacio de entrada, permitiendo al sistema capturar con mayor detalle las variaciones de la señal.

Sin embargo, el incremento en el número de MF también aumenta la complejidad computacional, por lo que se debe buscar un equilibrio entre precisión y eficiencia.

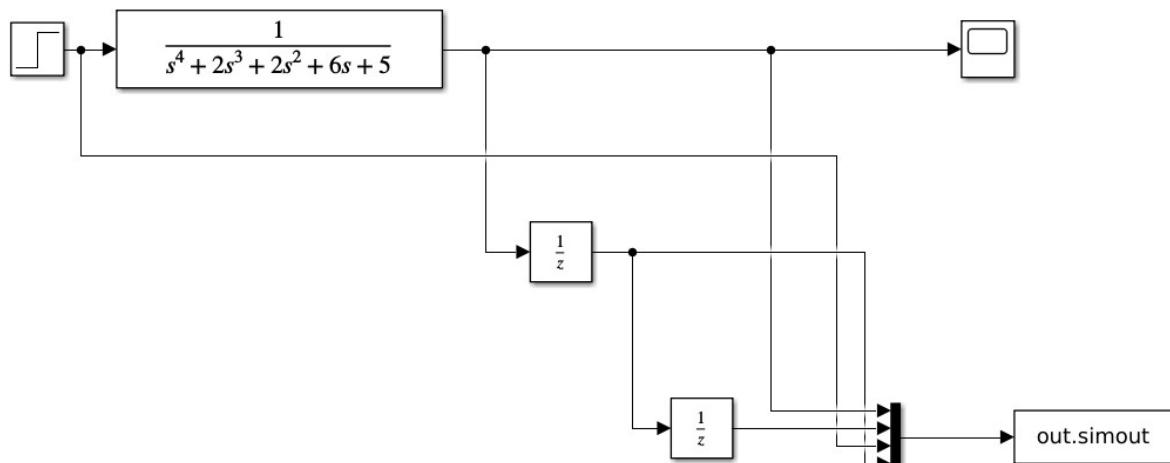
Las gráficas del error muestran que las diferencias entre la señal senoidal real y la generada por el ANFIS son muy pequeñas, con amplitudes del orden de 10^{-3} a 10^{-4} , lo que indica un excelente aprendizaje y generalización del modelo.

Punto 5

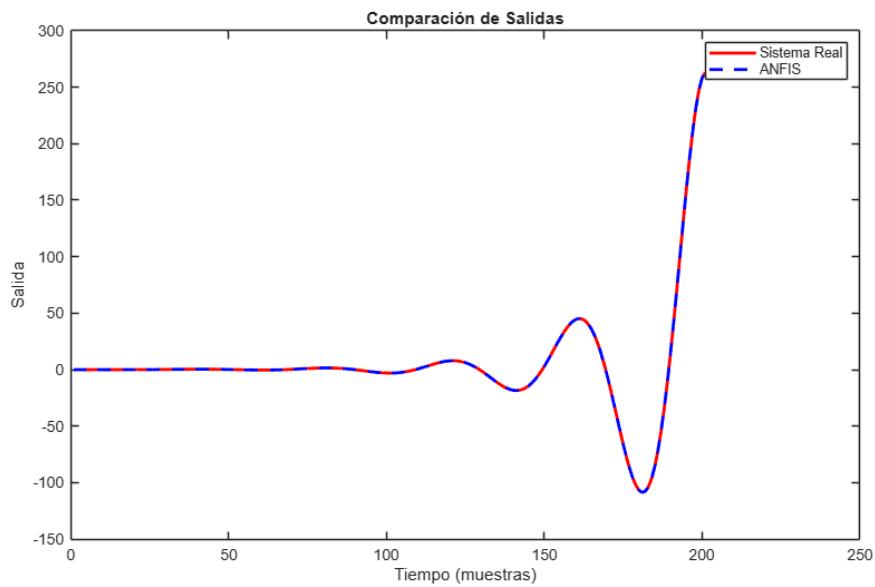
Se modela y aproxima el comportamiento dinámico de un sistema físico mediante un **modelo neuro-difuso adaptativo (ANFIS)**. En primer lugar, el modelo del sistema se implementa en **Simulink**, donde una señal de entrada (por ejemplo, un escalón) se aplica al bloque que representa la función de transferencia

$$G(s) = \frac{1}{s^4 + 2s^3 + 2s^2 + 6s + 5}$$

A través del bloque **To Workspace**, se envían al entorno de MATLAB tanto las variables de entrada como las salidas del sistema, conformando una matriz de datos (**simout**) con cuatro columnas: las tres primeras corresponden a variables de entrada (como la señal actual y sus retardos) y la cuarta a la salida real del sistema.



Posteriormente, en MATLAB, se configura un sistema de inferencia difusa tipo Takagi-Sugeno (TSK) usando la función `genfis` con la técnica de Grid Partitioning, definiendo el número y tipo de funciones de membresía para cada entrada (por ejemplo, “gbellmf”, “pimf” y “trimf”) y una función de salida de tipo lineal. Con este sistema inicial (`in_fis`) se entrena el modelo mediante el algoritmo ANFIS (`anfis(datos, in_fis, epoch_n)`), que ajusta los parámetros difusos y lineales minimizando el error entre la salida real y la estimada durante un número de épocas.



Una vez entrenado el modelo, se evalúa con los mismos datos de entrada (evalfis) para obtener la salida estimada del ANFIS (y_s), la cual se compara con la salida real (y_r) mediante una gráfica superpuesta que permite visualizar el grado de ajuste. Finalmente, se calculan los indicadores de desempeño: el error máximo porcentual y el error cuadrático medio (RMSE), que determinan si el modelo cumple los requisitos de precisión establecidos (error máximo menor al 5% y RMSE menor al 2%). Esta metodología permite validar que el modelo ANFIS reproduce adecuadamente el comportamiento dinámico del sistema original con un alto nivel de fidelidad.

